

AGI BAR

Local AI Gateway Management System

Web-first 本地 AI 網關 / 1 位管理員 / 1-50 位人員 / 獨立 API Key / Token 配額 / 時間權限 /
模型路由 / 安全上網

V1.1 系統規劃書 - Adobe 相容字型版

1. 專案目標

AGI BAR 是一套以瀏覽器為主要操作介面的本地 AI 網關管理系統。管理員在一台 AI 主機上啟動服務後，人員只要連上同一網路，即可透過網頁聊天，或使用 OpenAI API 相容方式連接各種 AI 開發工具與 App。

第一版規模鎖定 1 位 Admin + 1-50 位 User。每位人員擁有獨立 API Key，管理員可設定 Token 額度、有效日期、每日可使用時段、請求速率、優先級、是否允許上網，以及本地開源模型的優先使用順序。

2. 整體架構



3. 使用角色

角色	數量	權限
Admin 管理員	1	完整管理人員、API Key、模型、Token、上網、紀錄與系統設定
User 人員	1-50	使用 Web Chat 或 API；只能使用管理員核准的額度、時段與模型

4. Web 管理 UI

操作風格採一般網店後台模式，避免做成工程師伺服器控制台。左側選單：儀表板、人員、API、AI 模型、網路、紀錄、設定。

Dashboard 顯示：人員數、在線人數、API 請求數、今日 Token、目前 Queue、GPU/VRAM 使用率、目前主要模型、Internet 狀態。

5. 人員與 API Key 管理

每位人員建立後，自動產生獨立 API Key，例如 agi-bar-xxxxxxx。Key 不應直接以明文儲存在資料庫，建議只顯示建立當下完整值，資料庫保存雜湊與識別前綴。管理員可重新產生、停用或撤銷 Key。

設定項目	說明
狀態	啓用 / 暫停 / 停用
每日 Token	例如 500,000
每月 Token	例如 5,000,000

設定項目	說明
單次最大 Token	限制單一請求上下文與輸出量
有效日期	起始日與到期日
每日時段	例如 08:00-22:00，可限制工作日
RPM	每分鐘最大 Request 數
Concurrent	同時請求數，例如 1-3
Priority	Admin / High / Normal / Guest
Internet	允許 / 禁止 Web Search
Model Route	該人員可使用的模型與優先順序

6. Token Quota

配額採多層限制：單次最大 Token → 每小時 Token → 每日 Token → 每月 Token。超過限制可採 Hard Limit（拒絕請求）或 Soft Limit（自動降級至較小模型）。Input Token 與 Output Token 都需計入，並保存每次實際使用量。

7. 模型優先順序與自動切換

每位人員可配置獨立 Model Routing Chain。Gateway

不要求使用者知道實際後端模型名稱，而是依管理員設定自動路由。若順位 1 離線、VRAM 不足、Queue 過長或健康檢查失敗，自動嘗試順位 2，再依序切換。

模型路由器需持續執行 Health Check，至少記錄 Online/Offline、平均首 Token 延遲、Token/s、Queue、錯誤率與 VRAM 狀態。

8. Priority Queue

多人同時使用時，建議 P0 管理員、P1 高優先、P2 一般、P3 訪客；同時加入 anti-starvation，等待過久的低優先請求逐步提升權重，避免永遠排不到。

9. 本地模型安全上網

不建議直接讓 LLM 任意連 Internet。應由 AGI BAR 提供受控工具：Web Search、URL Fetch。Gateway 先檢查網址與網路政策，再擷取必要文字送給本地模型。

預設禁止 localhost、127.0.0.0/8、10.0.0.0/8、172.16.0.0/12、192.168.0.0/16、NAS/路由器/管理介面等內網位址，並設定最大下載大小、逾時、Content-Type 白名單與日誌。

10. 外部工具 / AI 客戶端串接

AGI BAR 對外提供 OpenAI-compatible API，讓不同 AI 工具共用同一個 Base URL 與各自的 API Key。第一版明確納入以下串接目標：

工具 / 平台	串接定位
Cursor	程式開發 IDE；透過 AGI BAR API 使用本地模型
Claude Code	CLI / Agent 開發工具；由可配置 Endpoint 或相容代理層接入 AGI BAR
Codex	OpenAI Codex 開發工作流；由 AGI BAR 的相容 API / 代理層依實際客戶端支援方式串接
DeepSeek	可作為外部雲端備援模型或相容 API 來源；是否啟用由管理員控制
自製 App	iOS / Android / Windows / Web App 皆可透過 AGI BAR API 使用
其他 OpenAI-compatible Client	只要允許自訂 Base URL 與 API Key，即可納入

重要：AGI BAR 的核心仍以「本地開源模型優先」為原則。DeepSeek 雲端或其他外部 API 若被加入，應作為管理員可選的備援/特殊用途路由，不應在未授權時把內部 Prompt 或程式碼送往外部。

```
Web UI：http://AI主機IP:8787
API Base URL：http://AI主機IP:8787/v1
API Key：每位人員自己的 agi-bar-xxxxxxx
```

11. Portable / 啟動方式

不以自製未簽章 EXE 作為主要入口。ZIP 解壓後，管理員使用透明的啟動腳本啟動服務，再由腳本自動開啓瀏覽器。Runtime、Web UI、Gateway、資料庫與可選的 llama.cpp Runtime 都放在同一資料夾內。

```
AGI-BAR/
├── 啟動 AGI BAR.cmd
├── 關閉 AGI BAR.cmd
├── web/
├── server/
├── runtime/
├── models/
├── data/
└── config/
```

Windows 防火牆仍可能要求允許本機服務接受 LAN 連線；企業 EDR 也可能依政策攔截腳本或網路服務，因此正式部署應由管理員核准固定 Port 與程式路徑。

12. 資料庫規劃

V1 可使用 SQLite，未來多人管理或多節點再升級 PostgreSQL。

資料表	用途
users	人員與角色
api_keys	Key 識別、雜湊、狀態
api_key_limits	Token / 時間 / RPM / Concurrent 限制
models	模型、Endpoint、狀態、能力
model_routes	每位人員的模型優先順序
usage_logs	Input/Output/Total Token 與模型使用量

資料表	用途
request_logs	時間、等待、推理、錯誤、Web 使用
system_settings	全域設定與安全政策

13. V1 開發順序

1. Portable 專案骨架與啟動/停止腳本
2. Web Admin 登入與 Dashboard
3. 人員 1-50 管理
4. API Key 建立、撤銷與驗證
5. Token / 時間 / RPM / Concurrent Quota
6. OpenAI-compatible /v1/models 與 /v1/chat/completions
7. 本地模型註冊與 Health Check
8. Model Routing Chain 與 Failover
9. Priority Queue + anti-starvation
10. Web Search / URL Fetch 安全代理
11. Cursor / Claude Code / Codex / DeepSeek / App 串接驗證
12. Usage Dashboard / Log
13. 備份、還原、設定匯出
14. LAN 多人壓力測試與安全驗收

14. V1 驗收標準

ZIP 解壓後可啟動；瀏覽器自動開啓管理頁；可建立 1-50 名人員；每人獨立 API Key；可限制 Token、有效日期與時段；可配置模型順序；主要模型失效可自動 Failover；多人請求有優先 Queue；可記錄每人 Token；本地模型可透過受控工具搜尋 Internet；Cursor、Claude Code、Codex、DeepSeek 路由與自製 App 可依各客戶端實際支援方式完成串接。

建議產品名稱：AGI BAR – Local AI Gateway Management System

15. GitHub 開發與版本管理流程

AGI BAR V1.2 將 GitHub 納入正式開發流程。GitHub 主要負責原始碼、Issue、版本、Release 與文件管理；模型檔、API Key、使用紀錄、資料庫與公司內部設定不得直接上傳至公開 Repository。

15.1 Repository 建議結構

```
agi-bar/  
├─ web/ Web UI  
├─ server/ Gateway / API / Queue / Router  
├─ scripts/ 啟動、停止、建置腳本  
├─ config/ config.example.json  
├─ docs/ 架構與部署文件  
├─ tests/ 測試  
├─ .github/ Issue / PR / Actions  
├─ .gitignore  
├─ README.md  
├─ LICENSE  
└─ CHANGELOG.md
```

15.2 開發流程

需求確認 → 建立 GitHub Issue → 建立功能分支 → Codex / Claude Code / Cursor 開發 → 本機測試 → Commit → Push → Pull Request → Code Review → 自動測試 → Merge main → 建立版本 Tag → GitHub Release → 產生 Portable ZIP → 部署 AGI BAR

15.3 Branch 規則

Branch	用途
main	穩定、可發布版本
develop	整合下一版本功能，可選
feature/xxx	新功能，例如 feature/api-key-quota
fix/xxx	Bug 修正
docs/xxx	文件與規格更新

15.4 AI 開發工具與 GitHub

Codex、Claude Code、Cursor 都以同一個 Git Repository 為工作基礎。AI 修改程式前先讀取 Issue 與目前 Branch，只修改該 Issue 範圍；完成後執行測試，再提交 Commit。避免多個 AI 同時直接修改 main。

建議分工：

Codex：實作、修正、測試、Git 操作。

Claude Code：大型功能、架構重構、Code Review。

Cursor：人工互動式修改與快速檢查。

DeepSeek：可作為本地/外部程式模型或第二意見，但仍走相同 Git 流程。

16. GitHub 安全與 Release 流程

16.1 絕對不可上傳的資料

API Key、管理員密碼、JWT Secret、.env、真實 config.json、users.db、usage.db、request logs、員工資料、模型授權憑證、內網 IP 清單、私有憑證與大型模型檔。這些項目必須加入 .gitignore; Repository 只保留 config.example.json 與示範資料。

16.2 GitHub Actions / CI

Pull Request 建議自動執行: 程式語法檢查 → 單元測試 → API 測試 → 安全掃描 → Portable 結構檢查。main 通過後才允許建立 Release。正式部署所需的敏感設定不放入 Actions Artifact。

16.3 Release 發布

main 穩定 → 建立版本號 (例如 v1.2.0) → 產生 CHANGELOG → 建立 GitHub Release → 建置 AGI-BAR-v1.2.0-win64.zip → 計算 SHA-256 → 上傳 Release Asset → 管理員下載 ZIP → 解壓 → 保留既有 data/config → 啟動 → 執行健康檢查。

16.4 Portable ZIP 與 GitHub 的關係

GitHub Repository 保存『程式碼』; GitHub Release 提供『可部署 ZIP』。大型 GGUF 模型不建議直接塞進 Git Repository。可由管理員在首次部署後放入 models/, 或由 AGI BAR 的模型管理頁下載到本機。

16.5 更新與回復

每次更新前自動備份 data/ 與 config/。新版程式與使用者資料分離, 因此更新 ZIP 不應覆蓋 API Key、Token 統計與人員資料。若新版異常, 可回復上一個 GitHub Release 版本並重新掛回原 data/。

17. V1.2 最終交付流程

```
graph TD
    A[GitHub Issue] --> B[Codex / Claude Code / Cursor / DeepSeek 協作]
    B --> C[Feature Branch]
    C --> D[Pull Request + Review + Tests]
    D --> E[main]
    E --> F[GitHub Release]
    F --> G[AGI-BAR Portable ZIP]
    G --> H[管理員解壓啟動]
    H --> I[Web UI 管理 1-50 名人員]
    I --> J[每人 API Key / Token / 時間 / Model Route]
```



本地 AI + 受控 Internet Access

版本: AGI BAR V1.2 - GitHub Workflow Edition